

Resolucao do Exercicio 1 - Estatistica Multivariada

Wagner com ajuda do Gemini CLI

May 7, 2026

Contents

1	Introducao	1
2	Exercicio 1: Analise de Dados Binarios (Presenca-Ausencia)	2
2.1	Codigo de Carregamento e Processamento	2
2.2	Resultados: Dendrogramas	3
3	Exercicio 2: Agrupamento K-means no Dataset IRIS	5
3.1	Abordagem 1: Metodo do Cotovelo (Elbow Method)	5
3.2	Abordagem 2: K-means Simples com Validacao Estatistica . .	8
4	Conclusao	12
5	saida completo do ex1 dendograma	13
6	saida completa do kmeans simples	15
7	saída completa do kmeans com elbow	18

1 Introducao

Este documento apresenta a resolucao da lista 1 de exercicios do nosso curso de introducao a analise estatística multivariada

Todos os scripts estao localizados na pasta `src/`.

Para mais detalhes tudo que foi realizado inclusive notas de estudos pode ser acessados em https://github.com/wagnermarques/curso_estatistica_multivariada

O código que produziu estes resultados abaixo se encontram neste mesmo repositório na pasta exercícios/exercicios1/src obrigado

2 Exercício 1: Análise de Dados Binários (Presença-Ausência)

O objetivo deste exercício é analisar a similaridade entre 8 espécies com base em dados binários utilizando diferentes coeficientes.

2.1 Código de Carregamento e Processamento

Os dados são carregados de um arquivo CSV e processados para calcular as matrizes de distância de Sørensen-Dice e Simple Matching.

```
import ex1_1_read_data_from_csv
import ex1_2_clustering_binario
from scipy.spatial.distance import squareform
import pandas as pd

# 1 read data from csv
df = ex1_1_read_data_from_csv.read_data()

print("--- Primeiras 10 linhas do dataframe ---")
print(df.head(10))

# 3 calcula matriz de distancias usando coeficiente Sorensen-Dice e Simple Matching
X = df.iloc[:, 1:].values
species = df.iloc[:, 0].values

#####
# criando e observando as matrizes de distancias #
#####
dist_dice = ex1_2_clustering_binario.calcular_matriz_distancias(X, metric='dice')
dist_sm = ex1_2_clustering_binario.calcular_matriz_distancias(X, metric='matching')

# Converter para formato quadrado para visualizacao
# isso porque sem essa conversao as mtz estao no formato otimizado o ndarray
df_dist_dice = pd.DataFrame(squareform(dist_dice), index=species, columns=species)
```

```

df_dist_sm = pd.DataFrame(squareform(dist_sm), index=species, columns=species)

print("\n--- Matriz de Distancia (Sorensen-Dice) ---")
print(df_dist_dice.round(3))

print("\n--- Matriz de Distancia (Simple Matching) ---")
print(df_dist_sm.round(3))

# 4 analyze the data using clustering_binario module (gera os dendrogramas)
print("\n--- Gerando Dendrogramas ---")
ex1_2_clustering_binario.plot_dendrogram(dist_dice, species, 'dice', 'Dendrograma - Sorensen-Dice')
ex1_2_clustering_binario.plot_dendrogram(dist_sm, species, 'matching', 'Dendrograma - Simple Matching')

# 5 Atribuindo grupos (exemplo de corte)
print("\n--- Atribuicao de Grupos (Exemplos) ---")

# Exemplo 1: Cortar o dendrograma Sorensen-Dice para obter 3 grupos
df_grupos_dice = ex1_2_clustering_binario.atribuir_grupos(dist_dice, species, t=3, criterio='altura')
print("\nGrupos (Sorensen-Dice, k=3):")
print(df_grupos_dice)

# Exemplo 2: Cortar o dendrograma Simple Matching na altura 0.4
df_grupos_sm = ex1_2_clustering_binario.atribuir_grupos(dist_sm, species, t=0.4, criterio='altura')
print("\nGrupos (Simple Matching, h=0.4):")
print(df_grupos_sm)

```

Figure 1: Script de Analise Binaria

2.2 Resultados: Dendrogramas

Os dendrogramas abaixo mostram como as especies se agrupam de acordo com cada metrica de distancia.




Figure 2: Dendrograma utilizando distancia Sorensen-Dice




Figure 3: Dendrograma utilizando distancia Simple Matching

3 Exercício 2: Agrupamento K-means no Dataset IRIS

Neste exercício, exploramos o algoritmo K-means para agrupar flores do dataset IRIS e validamos a qualidade dos grupos formados.

3.1 Abordagem 1: Metodo do Cotovelo (Elbow Method)

Esta abordagem foca em encontrar o numero otimo de grupos (k) analisando a variacao da soma dos quadrados intra-cluster (WCSS).

```
import ex2_1_load_iris
import ex2_2_clustering_iris
import pandas as pd
import numpy as np
from sklearn.preprocessing import StandardScaler

# 1. Leitura dos dados
df = ex2_1_load_iris.load_iris_data()

# 2. Mostrar as primeiras 10 linhas
print("--- Primeiras 10 linhas do dataset IRIS ---")
print(df.head(10))

# 3. Padronizacao (Escalonamento)
# Selecionamos as colunas numericas (SEPALLEN, SEPALWID, PETALLEN, PETALWID)
variaveis_list = ['SEPALLEN', 'SEPALWID', 'PETALLEN', 'PETALWID']
mtz_vlrs = df[variaveis_list].values
species = df['specie'].values

scaler = StandardScaler()
mtz_vlrs_padrozinados = scaler.fit_transform(mtz_vlrs)

print("\nDados padronizados (primeiras 5 linhas):")
print(mtz_vlrs_padrozinados[:5])

# 4. Metodo do Cotovelo (Elbow Method)
print("\n--- Analise do Numero Otimo de Grupos (Metodo do Cotovelo) ---")
ex2_2_clustering_iris.plot_elbow_method(
    mtz_vlrs_padrozinados,
```

```

        max_k=10,
        filename='kmeans_elbow_iris.png'
    )

# 5. Executar K-means
# Vamos utilizar k=3 pois sabemos que existem 3 especies no dataset IRIS
k_ideal = 3
print(f"\n--- Executando K-means (k={k_ideal}) ---")
df_grupos, kmeans_model = ex2_2_clustering_iris.executar_kmeans(
    mtz_vlrs_padrozinados,
    species,
    n_clusters=k_ideal
)

# Adicionando a informacao do grupo ao DataFrame original
df['Grupo'] = df_grupos['Grupo']

# 6. Mostrar resultados
print("\n--- Dados Originais com Atribuicao de Grupos (K-means) ---")
print(df.head(10))

# Verificar a contagem em cada grupo
print("\nContagem por grupo:")
print(df_grupos['Grupo'].value_counts())

# Comparar com as especies originais (Crosstab)
print("\n--- Cruzamento: Especie Original vs Grupo K-means ---")
print(pd.crosstab(df['specie'], df['Grupo']))

# 7. Visualizacao dos clusters
print("\n--- Gerando Grafico de Dispersao dos Clusters ---")
ex2_2_clustering_iris.plot_kmeans_clusters(
    mtz_vlrs_padrozinados,
    df_grupos['Grupo'].values,
    kmeans_model.cluster_centers_,
    filename='kmeans_scatter_iris.png'
)

# 8. Analise Univariada (ANOVA) - Verificando a qualidade dos grupos

```

```

import statsmodels.api as sm
from statsmodels.formula.api import ols

print("\n--- Analise de Variancia (ANOVA) por Variavel ---")
print("H0: Nao ha diferenca entre as medias dos grupos")
print("H1: Ha pelo menos uma diferenca entre as medias")

for var in variaveis_list:
    formula = f"{var} ~ C(Grupo)"
    model = ols(formula, data=df).fit()
    anova_table = sm.stats.anova_lm(model, typ=2)

    # Acessando os valores usando o nome da linha 'C(Grupo)'
    p_valor = anova_table.at['C(Grupo)', 'PR(>F)']
    f_stat = anova_table.at['C(Grupo)', 'F']

    print(f"\nVariavel: {var}")
    print(f"F-statistic: {f_stat:.4f}")
    print(f"p-valor: {p_valor:.4e}")

    if p_valor < 0.05:
        print("Resultado: Significativo (Existem diferencas entre os grupos)")
    else:
        print("Resultado: Nao significativo (Nao ha diferencas claras)")

# 9. Analise Multivariada de Variancia (MANOVA)
from statsmodels.multivariate.manova import MANOVA

print("\n--- Analise Multivariada de Variancia (MANOVA) ---")
print("H0: Os vetores de medias dos grupos sao iguais")
print("H1: Pelo menos um vetor de media e diferente")

# Criando a formula para todas as variaveis dependentes
formula_manova = " + ".join(variaveis_list) + " ~ C(Grupo)"
manova = MANOVA.from_formula(formula_manova, data=df)

# Exibindo os resultados (Wilks' lambda, Pillai's trace, etc)
print(manova.mv_test())

```

Figure 4: Script K-means com Metodo do Cotovelo

3.1.1 Graficos de Validacao do Numero de Grupos




Figure 5: Analise do Metodo do Cotovelo

3.2 Abordagem 2: K-means Simples com Validacao Estatistica

Nesta versao, definimos o numero de grupos diretamente e realizamos testes de ANOVA e MANOVA para verificar se os grupos sao estatisticamente distintos.

```
# %%
import ex2_1_load_iris
import ex2_2_clustering_iris
import pandas as pd
import numpy as np
from sklearn.preprocessing import StandardScaler

# 1. Leitura dos dados
df = ex2_1_load_iris.load_iris_data()
```





Figure 6: Dispersao dos Grupos (Cotovelo)

```
# 2. Mostrar as primeiras 10 linhas
print("--- Primeiras 10 linhas do dataset IRIS ---")
print(df.head(10))

# 3. Padronizacao (Escalonamento)
# Selecionamos as colunas numericas (SEPALLEN, SEPALWID, PETALLEN, PETALWID)
variaveis_list = ['SEPALLEN', 'SEPALWID', 'PETALLEN', 'PETALWID']
mtz_vlrs = df[variaveis_list].values
species = df['specie'].values

scaler = StandardScaler()
mtz_vlrs_padrozinados = scaler.fit_transform(mtz_vlrs)

print("\nDados padronizados (primeiras 5 linhas):")
print(mtz_vlrs_padrozinados[:5])

# 4. Definicao do numero de grupos
# Altere este valor para escolher quantos grupos deseja formar
n_grupos = 3
```

```

# 5. Executar K-means
print(f"\n--- Executando K-means (k={n_grupos}) ---")
df_grupos, kmeans_model = ex2_2_clustering_iris.executar_kmeans(
    mtz_vlrs_padrozinados,
    species,
    n_clusters=n_grupos
)

# Adicionando a informacao do grupo ao DataFrame original
df['Grupo'] = df_grupos['Grupo']

# 6. Mostrar resultados
print("\n--- Dados Originais com Atribuicao de Grupos (K-means) ---")
print(df.head(10))

# Verificar a contagem em cada grupo
print("\nContagem por grupo:")
print(df_grupos['Grupo'].value_counts())
print(df['Grupo'].value_counts())

# exibir nome das variaveis e os grupos atribuídos em df
print("\n--- Variaveis e Grupos Atribuidos ---")

# Comparar com as especies originais (Crosstab)
print("\n--- Cruzamento: Especie Original vs Grupo K-means ---")
print(pd.crosstab(df['specie'], df['Grupo']))

# 7. Visualizacao dos clusters
print("\n--- Gerando Grafico de Dispersao dos Clusters ---")
ex2_2_clustering_iris.plot_kmeans_clusters(
    mtz_vlrs_padrozinados,
    df_grupos['Grupo'].values,
    kmeans_model.cluster_centers_,
    filename='kmeans_scatter_iris_simple.png'
)

# 8. Analise Univariada (ANOVA) - Verificando a qualidade dos grupos

```

```

# 1. Iteração por Variável: Para cada uma das 4 variáveis (SEPALLEN, SEPALWID, etc.),
# 2. Teste de Hipótese:
#     * H0 (Hipótese Nula): As médias de todos os grupos são iguais para aquela variável
#     * H1 (Hipótese Alternativa): Pelo menos um grupo tem uma média significativamente diferente
# O script já interpreta o p-valor (usando o padrão de 5% ou 0.05) e te diz se o resultado é significativo
# Se os grupos forem bons, esperamos que o p-valor seja muito pequeno (ex: algo como 0.001)
# Pode rodar o script novamente para ver os resultados:
import statsmodels.api as sm
from statsmodels.formula.api import ols

print("\n--- Analise de Variância (ANOVA) por Variável ---")
print("H0: Não há diferença entre as médias dos grupos")
print("H1: Há pelo menos uma diferença entre as médias")

for var in variaveis_list:
    formula = f"{var} ~ C(Grupo)"
    model = ols(formula, data=df).fit()
    anova_table = sm.stats.anova_lm(model, typ=2)

    # Acessando os valores usando o nome da linha 'C(Grupo)'
    p_valor = anova_table.at['C(Grupo)', 'PR(>F)']
    f_stat = anova_table.at['C(Grupo)', 'F']

    print(f"\nVariável: {var}")
    print(f"F-statistic: {f_stat:.4f}")
    print(f"p-valor: {p_valor:.4e}")

    if p_valor < 0.05:
        print("Resultado: Significativo (Existem diferenças entre os grupos)")
    else:
        print("Resultado: Não significativo (Não há diferenças claras)")

# 9. Analise Multivariada de Variância (MANOVA)
from statsmodels.multivariate.manova import MANOVA

print("\n--- Analise Multivariada de Variância (MANOVA) ---")
print("H0: Os vetores de médias dos grupos são iguais")
print("H1: Pelo menos um vetor de média é diferente")

```

```

# Criando a formula para todas as variaveis dependentes
# Ex: "SEPALLEN + SEPALWID + PETALLEN + PETALWID ~ C(Grupo)"
formula_manova = " + ".join(variaveis_list) + " ~ C(Grupo)"
manova = MANOVA.from_formula(formula_manova, data=df)

# Exibindo os resultados (Wilks' lambda, Pillai's trace, etc)
print(manova.mv_test())

#from notebooklm
#referencias do livro Hair et al. (2024) para interpretação dos resultados da MANOVA:
#Aqui está como o livro orienta a interpretação de cada uma dessas quatro medidas estatísticas:
#Lambda de Wilks (Wilks' lambda): É a estatística mais comumente utilizada para testar a hipótese nula de que não há diferenças significativas entre os grupos em relação às variáveis dependentes.
#Critério de Pillai (Pillai's trace) e Traço de Hotelling (Hotelling-Lawley trace): São medidas alternativas para testar a hipótese nula.
#Maior raiz característica de Roy (Roy's greatest root): Diferentemente das outras três, esta medida é baseada no determinante da matriz de covariância dentro dos grupos.
##Como o livro recomenda escolher entre elas? Apesar de, na grande maioria das vezes, todas as medidas levarão à mesma conclusão, a escolha pode depender do contexto e do tamanho da amostra.
#Critério de Pillai: É considerado o teste mais robusto. O autor recomenda que ele seja usado quando houver preocupação com a violação das suposições de normalidade multivariada.
#Lambda de Wilks ou Pillai: São as medidas de preferência quando as considerações básicas forem atendidas.
#Maior Raiz de Roy: É o teste estatístico mais poderoso, mas apenas se o pesquisador estiver interessado em interpretar o resultado específico. Observando a sua tabela na seção C(Grupo), a maior raiz de Roy indica a direção da diferença entre os grupos.
##A interpretação prática usando as diretrizes do Hair é que, independentemente do critério escolhido, a interpretação dos resultados deve considerar o contexto da pesquisa e a importância das variáveis dependentes.
#Referências [fn:517] Hair et al., Análise Multivariada de Dados (Significância geral)

```

Figure 7: Script K-means Simples e Validacao

3.2.1 Análise de Resultados

A análise inclui:

- **Crosstab:** Comparação entre a espécie real e o grupo atribuído.
- **ANOVA:** Teste univariado para cada variável (SEPALLEN, SEPALWID, etc).
- **MANOVA:** Teste multivariado considerando todas as variáveis simultaneamente.

4 Conclusão

Consegui praticar a análise de agrupamento




Figure 8: Dispersao dos Grupos (Simples)

O Livro do hair nÃŁo fala do mÃŁtodo ebowl de kmeans mas percebi que as multiplos agrupamentos me pareceu resultar em grupos melhores que no kmeans simples onde eu escolhi 3 grupos e os grupos foram formados sem a inteligencia do ebowl. JÃŁ o dendrograma ÃŁ uma tÃŁcnica mais interessante porque podemos escolher o ponto de corte. Consegui colocar isso no cÃŁdigo, podemos cortar e obter os grupos. AgradeÃŁo muitÃŁssimo a oportunidade e a compreenÃŁsÃŁo.

5 saida completo do ex1 dendrograma

```
(venv) wgn@fedora:~/WORKING/Projects-Srcs/Projects-Srcs-FzlSoft/curso_estatistica_mult.
--- Primeiras 10 linhas do dataframe ---
  species  loc_1  loc_2  loc_3  loc_4  loc_5  loc_6  loc_7  loc_8  loc_9  loc_10  ...
0  esp_1      0      0      1      1      0      1      1      0      0      0      ...
1  esp_2      0      0      1      0      1      0      0      0      1      1      ...
2  esp_3      0      0      1      0      1      0      0      0      1      1      ...
3  esp_4      0      0      1      1      0      0      0      0      1      1      ...
4  esp_5      0      0      1      0      1      0      0      0      1      1      ...
5  esp_6      1      0      0      0      0      0      1      1      0      0      ...
```

6	esp_7	0	0	1	1	1	0	1	0	1	0	...
7	esp_8	1	0	0	0	0	1	1	0	1	1	...

[8 rows x 31 columns]

--- Matriz de Distancia (Sorensen-Dice) ---

	esp_1	esp_2	esp_3	esp_4	esp_5	esp_6	esp_7	esp_8
esp_1	0.000	0.478	0.500	0.360	0.565	0.680	0.429	0.615
esp_2	0.478	0.000	0.053	0.200	0.111	0.900	0.565	0.524
esp_3	0.500	0.053	0.000	0.238	0.053	0.905	0.500	0.455
esp_4	0.360	0.200	0.238	0.000	0.300	0.818	0.520	0.565
esp_5	0.565	0.111	0.053	0.300	0.000	0.900	0.478	0.524
esp_6	0.680	0.900	0.905	0.818	0.900	0.000	0.600	0.652
esp_7	0.429	0.565	0.500	0.520	0.478	0.600	0.000	0.615
esp_8	0.615	0.524	0.455	0.565	0.524	0.652	0.615	0.000

--- Matriz de Distancia (Simple Matching) ---

	esp_1	esp_2	esp_3	esp_4	esp_5	esp_6	esp_7	esp_8
esp_1	0.000	0.367	0.400	0.300	0.433	0.567	0.400	0.533
esp_2	0.367	0.000	0.033	0.133	0.067	0.600	0.433	0.367
esp_3	0.400	0.033	0.000	0.167	0.033	0.633	0.400	0.333
esp_4	0.300	0.133	0.167	0.000	0.200	0.600	0.433	0.433
esp_5	0.433	0.067	0.033	0.200	0.000	0.600	0.367	0.367
esp_6	0.567	0.600	0.633	0.600	0.600	0.000	0.500	0.500
esp_7	0.400	0.433	0.400	0.433	0.367	0.500	0.000	0.533
esp_8	0.533	0.367	0.333	0.433	0.367	0.500	0.533	0.000

--- Gerando Dendrogramas ---

Dendrograma salvo em: /home/wgn/WORKING/Projects-Srcs/Projects-Srcs-FzlSoft/curso_esta

Dendrograma salvo em: /home/wgn/WORKING/Projects-Srcs/Projects-Srcs-FzlSoft/curso_esta

--- Atribuicao de Grupos (Exemplos) ---

Grupos (Sorensen-Dice, k=3):

	Especie	Grupo
0	esp_1	1
1	esp_2	1
2	esp_3	1
3	esp_4	1
4	esp_5	1

```

5  esp_6      3
6  esp_7      1
7  esp_8      2

```

Grupos (Simple Matching, h=0.4):

```

    Especie Grupo
0  esp_1      1
1  esp_2      1
2  esp_3      1
3  esp_4      1
4  esp_5      1
5  esp_6      4
6  esp_7      2
7  esp_8      3

```

(venv)

wgn@fedora:~/WORKING/Projects-Srcs/Projects-Srcs-FzlSoft/curso_estadistica_multivari

6 saida completa do kmeans simples

(venv) wgn@fedora:~/WORKING/Projects-Srcs/Projects-Srcs-FzlSoft/curso_estadistica_mu

--- Primeiras 10 linhas do dataset IRIS ---

	specie	SEPALLEN	SEPALWID	PETALLEN	PETALWID
0	SETOSA	5.0	3.3	1.4	0.2
1	VIRGINIC	6.4	2.8	5.6	2.2
2	VERSICOL	6.5	2.8	4.6	1.5
3	VIRGINIC	6.7	3.1	5.6	2.4
4	VIRGINIC	6.3	2.8	5.1	1.5
5	SETOSA	4.6	3.4	1.4	0.3
6	VIRGINIC	6.9	3.1	5.1	2.3
7	VERSICOL	6.2	2.2	4.5	1.5
8	VERSICOL	5.9	3.2	4.8	1.8
9	SETOSA	4.6	3.6	1.0	0.2

Dados padronizados (primeiras 5 linhas):

```

[[-1.02184904  0.55861082 -1.34022653 -1.3154443 ]
 [ 0.67450115 -0.59237301  1.0469454  1.31719939]
 [ 0.79566902 -0.59237301  0.47857113  0.3957741 ]
 [ 1.03800476  0.09821729  1.0469454  1.58046376]
 [ 0.55333328 -0.59237301  0.76275827  0.3957741 ]]

```

--- Executando K-means (k=3) ---

--- Dados Originais com Atribuicao de Grupos (K-means) ---

	specie	SEPALLEN	SEPALWID	PETALLEN	PETALWID	Grupo
0	SETOSA	5.0	3.3	1.4	0.2	2
1	VIRGINIC	6.4	2.8	5.6	2.2	1
2	VERSICOL	6.5	2.8	4.6	1.5	3
3	VIRGINIC	6.7	3.1	5.6	2.4	1
4	VIRGINIC	6.3	2.8	5.1	1.5	3
5	SETOSA	4.6	3.4	1.4	0.3	2
6	VIRGINIC	6.9	3.1	5.1	2.3	1
7	VERSICOL	6.2	2.2	4.5	1.5	3
8	VERSICOL	5.9	3.2	4.8	1.8	1
9	SETOSA	4.6	3.6	1.0	0.2	2

Contagem por grupo:

Grupo

3 53

2 50

1 47

Name: count, dtype: int64

Grupo

3 53

2 50

1 47

Name: count, dtype: int64

--- Variaveis e Grupos Atribuidos ---

--- Cruzamento: Especie Original vs Grupo K-means ---

Grupo	1	2	3
-------	---	---	---

specie	1	2	3
--------	---	---	---

SETOSA	0	50	0
--------	---	----	---

VERSICOL	11	0	39
----------	----	---	----

VIRGINIC	36	0	14
----------	----	---	----

--- Gerando Grafico de Dispersao dos Clusters ---

Grafico de Clusters (Scatter) salvo em: /home/wgn/WORKING/Projects-Srcs/Projects-Srcs-I

--- Analise de Variancia (ANOVA) por Variavel ---

H0: Nao ha diferenca entre as medias dos grupos

H1: Ha pelo menos uma diferenca entre as medias

Variavel: SEPALLEN

F-statistic: 218.5710

p-valor: 9.0932e-45

Resultado: Significativo (Existem diferencas entre os grupos)

Variavel: SEPALWID

F-statistic: 79.9000

p-valor: 3.2655e-24

Resultado: Significativo (Existem diferencas entre os grupos)

Variavel: PETALLEN

F-statistic: 860.6367

p-valor: 7.0300e-82

Resultado: Significativo (Existem diferencas entre os grupos)

Variavel: PETALWID

F-statistic: 525.6988

p-valor: 1.0487e-67

Resultado: Significativo (Existem diferencas entre os grupos)

--- Analise Multivariada de Variancia (MANOVA) ---

H0: Os vetores de medias dos grupos sao iguais

H1: Pelo menos um vetor de media e diferente

Multivariate linear model

=====

```
-----
      Intercept      Value  Num DF  Den DF   F Value  Pr > F
-----
      Wilks' lambda  0.0104  4.0000 144.0000 3416.6552 0.0000
      Pillai's trace  0.9896  4.0000 144.0000 3416.6552 0.0000
Hotelling-Lawley trace 94.9071  4.0000 144.0000 3416.6552 0.0000
      Roy's greatest root 94.9071  4.0000 144.0000 3416.6552 0.0000
-----
```

C(Grupo)	Value	Num DF	Den DF	F Value	Pr > F
Wilks' lambda	0.0383	8.0000	288.0000	148.0632	0.0000
Pillai's trace	1.3728	8.0000	290.0000	79.3376	0.0000
Hotelling-Lawley trace	14.3967	8.0000	203.4024	258.0786	0.0000
Roy's greatest root	13.6070	4.0000	145.0000	493.2547	0.0000

```
(venv) wgn@fedora:~/WORKING/Projects-Srcs/Projects-Srcs-FzlSoft/curso_estadistica_mult
```

7 saÃda completa do kmeans com ebowl

```
(venv) wgn@fedora:~/WORKING/Projects-Srcs/Projects-Srcs-FzlSoft/curso_estadistica_mult
```

```
--- Primeiras 10 linhas do dataset IRIS ---
```

	specie	SEPALLEN	SEPALWID	PETALLEN	PETALWID
0	SETOSA	5.0	3.3	1.4	0.2
1	VIRGINIC	6.4	2.8	5.6	2.2
2	VERSICOL	6.5	2.8	4.6	1.5
3	VIRGINIC	6.7	3.1	5.6	2.4
4	VIRGINIC	6.3	2.8	5.1	1.5
5	SETOSA	4.6	3.4	1.4	0.3
6	VIRGINIC	6.9	3.1	5.1	2.3
7	VERSICOL	6.2	2.2	4.5	1.5
8	VERSICOL	5.9	3.2	4.8	1.8
9	SETOSA	4.6	3.6	1.0	0.2

```
Dados padronizados (primeiras 5 linhas):
```

```
[[-1.02184904  0.55861082 -1.34022653 -1.3154443 ]
 [ 0.67450115 -0.59237301  1.0469454  1.31719939]
 [ 0.79566902 -0.59237301  0.47857113  0.3957741 ]
 [ 1.03800476  0.09821729  1.0469454  1.58046376]
 [ 0.55333328 -0.59237301  0.76275827  0.3957741 ]]
```

```
--- Analise do Numero Otimo de Grupos (Metodo do Cotovelo) ---
```

```
Grafico do Cotovelo salvo em: /home/wgn/WORKING/Projects-Srcs/Projects-Srcs-FzlSoft/cu
```

```
--- Executando K-means (k=3) ---
```

```

--- Dados Originais com Atribuicao de Grupos (K-means) ---
      specie  SEPALLEN  SEPALWID  PETALLEN  PETALWID  Grupo
0   SETOSA      5.0      3.3      1.4      0.2      2
1  VIRGINIC      6.4      2.8      5.6      2.2      1
2  VERSICOL      6.5      2.8      4.6      1.5      3
3  VIRGINIC      6.7      3.1      5.6      2.4      1
4  VIRGINIC      6.3      2.8      5.1      1.5      3
5   SETOSA      4.6      3.4      1.4      0.3      2
6  VIRGINIC      6.9      3.1      5.1      2.3      1
7  VERSICOL      6.2      2.2      4.5      1.5      3
8  VERSICOL      5.9      3.2      4.8      1.8      1
9   SETOSA      4.6      3.6      1.0      0.2      2

```

Contagem por grupo:

Grupo

3 53

2 50

1 47

Name: count, dtype: int64

```

--- Cruzamento: Especie Original vs Grupo K-means ---

```

Grupo 1 2 3

specie

SETOSA 0 50 0

VERSICOL 11 0 39

VIRGINIC 36 0 14

```

--- Gerando Grafico de Dispersao dos Clusters ---

```

Grafico de Clusters (Scatter) salvo em: /home/wgn/WORKING/Projects-Srcs/Projects-Srcs-I

```

--- Analise de Variancia (ANOVA) por Variavel ---

```

H0: Nao ha diferenca entre as medias dos grupos

H1: Ha pelo menos uma diferenca entre as medias

Variavel: SEPALLEN

F-statistic: 218.5710

p-valor: 9.0932e-45

Resultado: Significativo (Existem diferencas entre os grupos)

Variavel: SEPALWID

F-statistic: 79.9000
 p-valor: 3.2655e-24
 Resultado: Significativo (Existem diferencas entre os grupos)

Variavel: PETALLEN
 F-statistic: 860.6367
 p-valor: 7.0300e-82
 Resultado: Significativo (Existem diferencas entre os grupos)

Variavel: PETALWID
 F-statistic: 525.6988
 p-valor: 1.0487e-67
 Resultado: Significativo (Existem diferencas entre os grupos)

--- Analise Multivariada de Variancia (MANOVA) ---

H0: Os vetores de medias dos grupos sao iguais

H1: Pelo menos um vetor de media e diferente

Multivariate linear model

=====

Intercept	Value	Num DF	Den DF	F Value	Pr > F
Wilks' lambda	0.0104	4.0000	144.0000	3416.6552	0.0000
Pillai's trace	0.9896	4.0000	144.0000	3416.6552	0.0000
Hotelling-Lawley trace	94.9071	4.0000	144.0000	3416.6552	0.0000
Roy's greatest root	94.9071	4.0000	144.0000	3416.6552	0.0000

C(Grupo)	Value	Num DF	Den DF	F Value	Pr > F
Wilks' lambda	0.0383	8.0000	288.0000	148.0632	0.0000
Pillai's trace	1.3728	8.0000	290.0000	79.3376	0.0000
Hotelling-Lawley trace	14.3967	8.0000	203.4024	258.0786	0.0000
Roy's greatest root	13.6070	4.0000	145.0000	493.2547	0.0000

(venv) wgn@fedora:~/WORKING/Projects-Srcs/Projects-Srcs-FzlSoft/curso_estadistica_mult.